

Uma Introdução Prática a Knowledge Distillation em Imagens Médicas

Ministrantes:

Mirela Cazzolato, Graciella Favoreto e Mariana Suzuki



Observação:

Para visualizar todas as animações, é necessário entrar no modo Apresentação de Slides



Ministrantes



Mirela Cazzolato

Ministrante



Graciella Favoreto

Ministrante



Mariana Suzuki

Ministrante

Short bio



Mirela Cazzolato

Ministrante

- Professora Assistente no Instituto de Ciências Matemáticas e de Computação (ICMC) da Universidade de São Paulo (USP). É professora convidada e Supervisora Acadêmica no MBA em Inteligência Artificial e Big Data oferecido pelo ICMC.
- Foi Professora Assistente do Departamento de Computação e Matemática (DCM) da Faculdade de Filosofia, Ciências e Letras de Ribeirão Preto (FFCLRP) da USP.
- Doutora em Ciência da Computação e Matemática Computacional pelo ICMC, com estágio no Instituto de Tecnologia de Karlsruhe (KIT), Alemanha.

Realizou Pós-Doutorado pelo InCor no projeto temático MIVisBD FAPESP, atuando junto ao ICMC. Realizou estágio BEPE de Pós-Doutorado na Carnegie Mellon University (CMU), EUA. Tem interesse de pesquisa em Mineração de Grafos, Detecção de Anomalias, Dados Complexos, Análise e Mineração de Imagens, Aprendizado de Máquina e Visualização.

Short bio



Graciella Favoreto

Ministrante

- Doutoranda em Ciências de Computação e Matemática Computacional no ICMC-USP e graduada em Informática Biomédica pela FMRP-USP.
- Integra o projeto temático IHealth-MD e é membro do Grupo de Bases de Dados e Imagens (GBdI) do ICMC-USP, bem como do Medical Artificial Intelligence Laboratory (MAInLab) da FMRP-USP.
- Atualmente, também desenvolve pesquisas envolvendo técnicas de knowledge distillation para construção de modelos mais eficientes e escaláveis.

Atua em projetos de pesquisa na área de Inteligência Artificial aplicada à saúde, com ênfase em visão computacional para análise de imagens médicas. Seus trabalhos concentram-se no desenvolvimento de métodos de aprendizado profundo para apoio ao diagnóstico, incluindo tarefas de segmentação, classificação, multimodalidade e interpretabilidade de modelos.

Short bio



Mariana Suzuki

Ministrante

- Mestra em Ciências de Computação e Matemática Computacional pelo ICMC/USP e bacharel em Informática Biomédica pela FMRP/USP. Atualmente é doutoranda em Ciências de Computação e Matemática Computacional pelo ICMC/USP e integrante do projeto IHealth-MD
- Durante o mestrado, propôs um framework para apoiar o treinamento de modelos de segmentação automatizada de imagens médicas, utilizando técnicas de aumento e redução de dados, com imagens reais e sintéticas.
- Na graduação, desenvolveu trabalho de conclusão de curso sobre segmentação automatizada de corpos vertebrais.

Recebeu o Best Student Paper Award no IEEE CBMS 2025. Atua com imagens médicas, extração de características de imagens, inteligência artificial e visão computacional.



Introdução e Motivação

Pneumonia

- Diagnóstico complexo
- Similaridade de sintomas

Diagnóstico Manual

- Desgaste profissional
- Suscetível a erros

Modelos de deep learning

- Modelos de larga escala e complexidade
- Implantação

Como manter o desempenho de classificação e reduzir o custo computacional de um modelo de classificação para detecção de pneumonia?



Objetivo

Neste curso, serão abordados conceitos fundamentais de Knowledge Distillation (KD), com exposição teórica e prática dos modelos, sua aplicabilidade e a importância do KD no domínio médico e na tarefa de classificação de imagens. Serão apresentadas noções teóricas básicas de processamento de imagens, pré-processamento, conceitos de KD e de função de perda. Na parte prática do curso, será desenvolvido um pipeline básico utilizando bibliotecas Python abertas, exemplificando os conceitos expostos e a utilidade da abordagem no domínio médico.



Agenda

Introdução	Ministrantes Motivação Objetivo
Teoria	Diagnóstico Auxiliado por Computador Knowledge Distillation • Tipos de conhecimento • Tipos de destilação
Prática	Pré-requisitos Modelo Professor Modelo Aprendiz Destilação de Conhecimento Avaliação
Conclusões	Encerramento



Diagnóstico Auxiliado Por Computador



Diagnóstico Auxiliado por Computador

Principal objetivo
Auxiliar profissionais da saúde
no processo de diagnóstico

Interpretação
de imagens

Detecção de
anomalias

Identificar
regiões de
interesse

Quantificar
anomalias

Reduzir
desgaste do
profissional



Diagnóstico Auxiliado por Computador

Aquisição

Radiografia
Tomografia computadorizada
Ressonância magnética

Anotação

Identificação de características relevantes
Região de interesse
• Forma, textura e bordas

Pré-processamento

Melhorar a qualidade das imagens
• Redução de ruídos
• Aumento de contraste

Algoritmos

Analisar características extraídas
Identificar e aprender padrões associados a diversas condições médicas

Classificação das regiões de interesse

- Segunda opinião

Diagnóstico Auxiliado por Computador


Algoritmos

Analisar características extraídas
Identificar e aprender padrões
associados a diversas condições
médicas

Classificação das
regiões de interesse


- Segunda opinião

Deep Neural Networks (Redes Neurais Profundas)




Deep Neural Networks (Redes Neurais Profundas)

Múltiplas camadas para criar a representação de uma imagem e determinar como classificá-la



Identificar diferentes padrões e características da imagem de entrada

Deep Neural Networks (Redes Neurais Profundas) - Estrutura




Deep Neural Networks (Redes Neurais Profundas) - Estrutura

Inserida entre camadas de convolução para
sumarizar as características extraídas

Camada de pooling


Max Pooling

Input (26, 26)



$$\max\left(\begin{matrix} 2.66 & 2.96 \\ 3.01 & 2.98 \end{matrix}\right) = 3.01$$

Output (13, 13)




Hover over the matrices to change kernel position.

Extração de
características

Max

3	4	1	2
2	5	3	0
1	2	1	0
4	3	1	7

Camada totalmente
conectada




5	3
4	7

Resultado


Camada de **max pooling** seleciona o valor mais
alto em uma região como o resultado dessa região

Deep Neural Networks (Redes Neurais Profundas) - Estrutura



Deep Neural Networks (Redes Neurais Profundas) - Estrutura

Camada totalmente conectada



Cada neurônio é conectado a outros neurônios em camadas diferentes

Função de ativação SoftMax para produzir probabilidades entre 0 e 1


Camada totalmente conectada



Resultado

Classificação

Deep Neural Networks (Redes Neurais Profundas) - Estrutura





Deep Neural Networks (Redes Neurais Profundas) - Estrutura

Modelos de grande porte

Consomem uma grande quantidade de recursos computacionais e de memória

ResNet18_Weights.IMAGENET1K_V1:

These weights reproduce closely the results of the paper using a simple training recipe. Also available as `ResNet18_Weights.DEFAULT`.

acc@1 (on ImageNet-1K)	69.758
acc@5 (on ImageNet-1K)	89.078
min_size	height=1, width=1
categories	tench, goldfish, great white shark, ... (997 omitted)
num_params	11689512
recipe	link
GFLOPS	1.81
File size	44.7 MB

VGG16_Weights.IMAGENET1K_V1:

These weights were trained from scratch by using a simplified training recipe. Also available as `VGG16_Weights.DEFAULT`.

acc@1 (on ImageNet-1K)	71.592
acc@5 (on ImageNet-1K)	90.382
min_size	height=32, width=32
categories	tench, goldfish, great white shark, ... (997 omitted)
recipe	link
num_params	138357544
GFLOPS	15.47
File size	527.8 MB




Knowledge Distillation



Knowledge Distillation (Destilação de Conhecimento)

A destilação de conhecimento é uma técnica que visa transferir os aprendizados de um grande modelo pré-treinado para um modelo menor




O objetivo é treinar um modelo mais compacto para imitar um modelo maior e mais complexo



“Em muitos cenários do mundo real, a precisão e a capacidade de um modelo de inteligência artificial não são, por si só, suficientes para tornar o modelo útil, ele também deve caber no orçamento de tempo disponível, memória, dinheiro e recursos computacionais”

Porque aplicar destilação de conhecimento


Framework geral



Fonte: Gou, J., Yu, B., Maybank, S.J. et al. Knowledge Distillation: A Survey. Int J Comput Vis 129, 1789–1819 (2021).

<https://doi.org/10.1007/s11263-021-01453-z>

Framework geral



Fonte: Gou, J., Yu, B., Maybank, S.J. et al. Knowledge Distillation: A Survey. Int J Comput Vis 129, 1789–1819 (2021).

<https://doi.org/10.1007/s11263-021-01453-z>


Framework geral

Modelo Aprendiz

- Replica o modelo Professor para atingir desempenho equivalente ou superior
- Modelo com menos parâmetros, treinado com menos exemplos

Como transferir o conhecimento de um modelo Professor de grande porte para um modelo Aprendiz de pequeno porte?

Student Model



Fonte: Gou, J., Yu, B., Maybank, S.J. et al. Knowledge Distillation: A Survey. Int J Comput Vis 129, 1789–1819 (2021).


<https://doi.org/10.1007/s11263-021-01453-z>

Framework geral

Como transferir o conhecimento de um modelo Professor de grande porte para um modelo Aprendiz de pequeno porte?

Transferência do conhecimento



- Compressão do modelo Professor
- Aprendiz imita a saída final e o raciocínio para chegar até essa saída
- Como um modelo generaliza para novos dados após o treinamento



Fonte: Gou, J., Yu, B., Maybank, S.J. et al. Knowledge Distillation: A Survey. Int J Comput Vis 129, 1789–1819 (2021).

<https://doi.org/10.1007/s11263-021-01453-z>

Framework geral



Fonte: Gou, J., Yu, B., Maybank, S.J. et al. Knowledge Distillation: A Survey. Int J Comput Vis 129, 1789–1819 (2021).


<https://doi.org/10.1007/s11263-021-01453-z>



Tipos de conhecimento

Baseado em Respostas

Reproduzir diretamente a predição final do modelo professor




Baseado em Respostas

Logits

Resultados da última camada do modelo


Target

Predição final após os logits passarem pela função Softmax




Fonte: LI, Xiang et al. Knowledge distillation and teacher-student learning in medical imaging: Comprehensive zoverview, pivotal role, and future directions. Medical Image Analysis, p. 103819, 2025.


Baseado em Respostas



Estrutura



Baseado em Respostas



Baseado em Respostas




Função de perda

$$L_{target} = \alpha L_{soft} + \beta L_{hard}$$

Temperatura

Coeficiente que controla a distribuição de probabilidades entre as classes

- Suaviza as previsões geradas pelo professor
- Revela relações entre classes suprimidas pelas hard-labels



Baseado em Respostas

Temperatura


Coeficiente que controla a distribuição de probabilidades entre as classes

- Suaviza as previsões geradas pelo professor
- Revela relações intraclasses suprimidas pelas hard-labels

Função softmax


$$p(z_i, T) = \frac{\exp(z_i/T)}{\sum_j \exp(z_j/T)}$$

Função softmax com coeficiente de Temperatura é usada para calcular a probabilidade da classe de um soft-target




Baseado em Características

Extensão do Conhecimento Baseado em Resposta para o treinamento de redes mais profundas




Baseado em Relações

Analisa as relações entre diferentes camadas ou amostras





Tipos de conhecimento



Fonte: Gou, J., Yu, B., Maybank, S.J. et al. Knowledge Distillation: A Survey. Int J Comput Vis 129, 1789–1819 (2021).

<https://doi.org/10.1007/s11263-021-01453-z>

Tipos de conhecimento



Fonte: Gou, J., Yu, B., Maybank, S.J. et al. Knowledge Distillation: A Survey. Int J Comput Vis 129, 1789–1819 (2021).

<https://doi.org/10.1007/s11263-021-01453-z>




Tipos de destilação

Destilação Offline

Destilação offline

- Abordagem tradicional de destilação
- Treinamento em dois estágios
 - Professor treinado antes da destilação
 - Logits das características são extraídos para guiar o treinamento do modelo Aprendiz




Destilação Online



Destilação online


- Tanto o Professor quanto o Aprendiz são atualizados simultaneamente



Autodestilação

Autodestilação


- As mesmas redes são usadas para os modelos Professor e Aprendiz
- Caso especial
- Conhecimento das seções mais profundas é destilado para as partes mais superficiais da rede





Knowledge Distillation em Imagens Médicas

KD em Imagens Médicas



- Aumento das pesquisas sobre KD em imagens médicas
- 28% das pesquisas em MRI
- 37% das pesquisas sobre **segmentação** e 29% sobre **classificação de imagens**

Fonte: LI, Xiang et al. Knowledge distillation and teacher-student learning in medical imaging: Comprehensive overview, pivotal role, and future directions. Medical Image Analysis, p. 103819, 2025.



KD em Imagens Médicas

Diferenças entre KD em imagens naturais e médicas:

Dados disponíveis	Tipos de conhecimento	Generalização do conhecimento	Interpretabilidade
• Poucos dados médicos • Anotação custosa • Evitar overfitting	• Características complexas • Órgãos, tecidos e lesões	• Especificidade • Um tipo de conhecimento pode não ser aplicável para múltiplas patologias	• “O quê” e “de onde” - o conhecimento do modelo Aprendiz

Considerar aplicações clínicas e interpretabilidade dos resultados




KD em Imagens Médicas

Considerar aplicações clínicas e interpretabilidade dos resultados


Compressão de modelo	O modelo de menor escala (Aprendiz) pode ser facilmente implantado em aparelhos portáteis e hospitais
Compensar modalidades faltantes	O modelo Professor aprende uma representação comum no contexto de multimodalidades médicas e a rede Aprendiz simula a situação de modalidades faltantes na prática clínica
Interpretabilidade	O processo de aprendizado iterativo evidencia o local de lesões para promover interpretabilidade O modelo Professor simula o processo de diagnóstico realizado por profissionais de saúde

KD em Imagens Médicas



Fonte: LI, Xiang et al. Knowledge distillation and teacher-student learning in medical imaging: Comprehensive overview, pivotal role, and future directions. Medical Image Analysis, p. 103819, 2025.

KD em Imagens Médicas



Fonte: LI, Xiang et al. Knowledge distillation and teacher-student learning in medical imaging: Comprehensive overview, pivotal role, and future directions. Medical Image Analysis, p. 103819, 2025.



Intervalo (15 minutos)




Uma introdução prática a Knowledge Distillation em Imagens Médicas



1 - Pré-requisitos

- 1 GPU, 4GB de memória
- PyTorch v2.0 ou superior
- Conjunto MedMNIST





2 - Modelo Professor

- Carregar pesos já treinados
- ResNet18
- Modelo mais pesado do curso

In [2]:

```
teacher = build_teacher().to(device)

print(f"Teacher parameters: {count_parameters(teacher):,}")
```

Teacher parameters: 11,171,266



3 - Modelo Aprendiz

- Treinamento de uma SmallCNN
- Sem a ajuda do professor
- Baseline para comparação

In [2]:

```
student = SmallCNN().to(device)

print(f"Student parameters: {count_parameters(student):,}")
```

Student parameters: 23,426



4 - Knowledge Distillation

O Professor já treinado e congelado orienta o modelo SmallCNN

✓ Por que usar um student?

Comparamos custo computacional: parâmetros, tamanho em disco e tempo de inferência.

```
[ ] compare_models({"Teacher": teacher, "Student": student, "Student (KD, T=4)": student_kd_4, "Student (KD, T=10)": student_kd_10})
```




	Parâmetros	Tamanho (MB)	Latência (ms/batch)
Teacher	11171266.0	44.69	13.45
Student	23426.0	0.09	2.62
Student (KD, T=4)	23426.0	0.09	2.63
Student (KD, T=10)	23426.0	0.09	2.66




5 – Avaliação final

Comparar Professor,
Aprendiz baseline e
Aprendiz + KD com
diferentes temperaturas



5 – Avaliação final

Comparar Professor, Aprendiz baseline e Aprendiz + KD com diferentes temperaturas





Conclusões

Compreender os princípios básicos de um pipeline de processamento de imagem, incluindo pré-processamento

Compreender os conceitos gerais de *Knowledge Distillation* (KD);

Compreender a utilização da *distillation loss* clássica


Entender a importância de KD para imagens médicas e problemas associados;

Implementação de um pipeline básico de KD sobre bases públicas de imagens médicas;

Reconhecer limitações e desafios práticos em aplicações com bases de dados reais.



Ministrantes



Mirela Cazzolato
mirela@icmc.usp.br



Graciella Favoreto
graciellafavoreto@usp.br



Mariana Suzuki
mariaya25@usp.br

GitHub:



Linkedin:





Referências

1. HINTON, Geoffrey; VINYALS, Oriol; DEAN, Jeff. Distilling the knowledge in a neural network. DOI: <https://doi.org/10.48550/arXiv.1503.02531>, 2015.
2. GOU, Jianping; YU, Baosheng; MAYBANK, Stephen J.; TAO, Dacheng. Knowledge distillation: A survey. International Journal of Computer Vision, DOI: <https://doi.org/10.1007/s11263-021-01453-z>. v. 129, n. 6, p. 1789-1819, 2021.
3. LI, Xiang; LI, Like; LI, Minglei; YAN, Pengfei; FENG, Ting; LUO, Hao; ZHAO, Yong; YIN, Shen. Knowledge distillation and teacher–student learning in medical imaging: Comprehensive overview, pivotal role, and future directions. DOI: <https://doi.org/10.1016/j.media.2025.103819>. v.107, p.1-44, 2026.
4. MANSOURIAN, Amir M.; AHMADI, Rozhan; GHAFOURI, Masoud; BABAEI, Amir Mohammad; GOLEZANI, Elaheh Badali; GHAMCHI, Zeynab Yasamani; RAMEZANIAN, Vida; TAHERIAN, Alireza; Dinashi, Kimia; Miri, Amirali; Kasaei, Shohreh: A Comprehensive Survey on Knowledge Distillation. Transactions on Machine Learning Research. Open Review: <https://openreview.net/forum?id=3cbJzdR78B>. 2025.
5. ASHAM, Mohammed A.; AL-SHARGABI, Asma A.; AL-SABRI, Raeed; MEFTAH, Ibrahim. A lightweight deep learning model with knowledge distillation for pulmonary diseases detection in chest X-rays. vol. 84, p. 14885–14913. DOI: <https://doi.org/10.1007/s11042-024-19638-2>. 2025.
6. BERGMANN, Dave. Destilação de conhecimento. Disponível em: <<https://www.ibm.com/br-pt/think/topics/knowledge-distillation>>. Acesso em: 17 set.. 2026.
7. ZGALLAI, Walid A.; OZSAHIN, Dilber Uzun (Ed.). Artificial intelligence and image processing in medical imaging. Elsevier, 2024.
8. PRAKASH, Deo; GUPTA, Abhishek. Introduction to computer-aided diagnosis (CAD) tools and applications. In: Advances in Computers. Elsevier, 2025. p. 1-69.
9. dos Santos Favoreto, G., Suzuki Uchida, M. A., Luiz, P. A., Julio de Aguiar, E., Koenigkam Santos, M., Machado Traina, A. J. (2026). CoSegXAI: A Pipeline for Context vs. Segmented ROI Images in Lung Disease Classification through Saliency Map Insights. Revista De Informática Teórica E Aplicada, 33(2), 73–80. <https://doi.org/10.22456/2175-2745.150955>
10. WANG, Zijie J. et al. CNN explainer: learning convolutional neural networks with interactive visualization. IEEE Transactions on Visualization and Computer Graphics, v. 27, n. 2, p. 1396-1406, 2020.

Uma Introdução Prática a Knowledge Distillation em Imagens Médicas

Ministrantes:

Mirela Cazzolato, Graciella Favoreto e Mariana Suzuki

Página do Minicurso



<https://mtcazzolato.github.io/eabda-kd>

Os slides e os scripts do curso serão disponibilizados nesta página em breve. [Ver slides e scripts →](#)

X ESCOLA AVANÇADA DE BIG DATA ANALYSIS · ICMC/USP

Uma introdução prática a Knowledge Distillation em Imagens Médicas

Como ensinar um modelo pequeno a imitar um modelo grande, e por que isso importa para levar inteligência artificial ao diagnóstico por imagem. Teoria e prática em Python, classificando pneumonia em radiografias de tórax.

Seg., 05/10/2026

14h às 18h

Online, ao vivo

Gratuito, com certificado USP



Com as doutorandas **Graciella Favoreto** e **Mariana Suzuki** e a profa. **Mirela Cazzolato**, do GBdl · ICMC/USP.

Slides e scripts

Conheça as ministrantes

O QUE VAMOS DESTILAR



Professor
ResNet18
11.171.266 parâmetros

DESTILAÇÃO

Aprendiz
SmallCNN
23.426 parâmetros

≈ 477x menos parâmetros no aprendiz

Área de cada quadrado proporcional ao número de parâmetros do modelo.

O curso

Ministrantes

Programa

Conceitos

Prática

Slides e scripts

Materiais

Referências



Material Complementar



01

Produção Científica

Knowledge Distillation with Hybrid Soft-Label Losses for
Imbalanced Lung Nodule Classification



Produção Científica

Knowledge Distillation with Hybrid Soft-Label Losses for Imbalanced Lung Nodule Classification

Como manter alto desempenho de classificação e reduzir a complexidade computacional?


- Detecção de câncer de pulmão
- CAD como “segunda opinião”
- Especificidade e sensibilidade superiores

Fonte: Artigo completo apresentado no 39º IEEE INTERNATIONAL SYMPOSIUM ON COMPUTER-BASED MEDICAL SYSTEMS (CBMS), 2026. Atualmente em processo de publicação. Favoreto, G. S.; Aguiar, E. J.; Campos, L. O.; Cazzolato, M. T.; Santos, M. K.; Traina, A. J. M.. Knowledge Distillation with Hybrid Soft-Label Losses for Imbalanced Lung Nodule Classification. 2026, Limassol, Cyprus.

Produção Científica

Knowledge Distillation with Hybrid Soft-Label Losses for Imbalanced Lung Nodule Classification

Metodologia:




Fonte: Artigo completo apresentado no 39º IEEE INTERNATIONAL SYMPOSIUM ON COMPUTER-BASED MEDICAL SYSTEMS (CBMS), 2026. Atualmente em processo de publicação. Favoreto, G. S.; Aguiar, E. J.; Campos, L. O.; Cazzolato, M. T.; Santos, M. K.; Traina, A. J. M.. Knowledge Distillation with Hybrid Soft-Label Losses for Imbalanced Lung Nodule Classification. 2026, Limassol, Cyprus.

Produção Científica

Knowledge Distillation with Hybrid Soft-Label Losses for Imbalanced Lung Nodule Classification

Metodologia:




Fonte: Artigo completo apresentado no 39º IEEE INTERNATIONAL SYMPOSIUM ON COMPUTER-BASED MEDICAL SYSTEMS (CBMS), 2026. Atualmente em processo de publicação. Favoreto, G. S.; Aguiar, E. J.; Campos, L. O.; Cazzolato, M. T.; Santos, M. K.; Traina, A. J. M.. Knowledge Distillation with Hybrid Soft-Label Losses for Imbalanced Lung Nodule Classification. 2026, Limassol, Cyprus.

Produção Científica

Knowledge Distillation with Hybrid Soft-Label Losses for Imbalanced Lung Nodule Classification

Metodologia:




Fonte: Artigo completo apresentado no 39º IEEE INTERNATIONAL SYMPOSIUM ON COMPUTER-BASED MEDICAL SYSTEMS (CBMS), 2026. Atualmente em processo de publicação. Favoreto, G. S.; Aguiar, E. J.; Campos, L. O.; Cazzolato, M. T.; Santos, M. K.; Traina, A. J. M.. Knowledge Distillation with Hybrid Soft-Label Losses for Imbalanced Lung Nodule Classification. 2026, Limassol, Cyprus.

Produção Científica

Knowledge Distillation with Hybrid Soft-Label Losses for Imbalanced Lung Nodule Classification

Metodologia:




Fonte: Artigo completo apresentado no 39º IEEE INTERNATIONAL SYMPOSIUM ON COMPUTER-BASED MEDICAL SYSTEMS (CBMS), 2026. Atualmente em processo de publicação. Favoreto, G. S.; Aguiar, E. J.; Campos, L. O.; Cazzolato, M. T.; Santos, M. K.; Traina, A. J. M.. Knowledge Distillation with Hybrid Soft-Label Losses for Imbalanced Lung Nodule Classification. 2026, Limassol, Cyprus.

Produção Científica

Knowledge Distillation with Hybrid Soft-Label Losses for Imbalanced Lung Nodule Classification

Metodologia:



Fonte: Artigo completo apresentado no 39º IEEE INTERNATIONAL SYMPOSIUM ON COMPUTER-BASED MEDICAL SYSTEMS (CBMS), 2026. Atualmente em processo de publicação. Favoreto, G. S.; Aguiar, E. J.; Campos, L. O.; Cazzolato, M. T.; Santos, M. K.; Traina, A. J. M.. Knowledge Distillation with Hybrid Soft-Label Losses for Imbalanced Lung Nodule Classification. 2026, Limassol, Cyprus.

Produção Científica

Knowledge Distillation with Hybrid Soft-Label Losses for Imbalanced Lung Nodule Classification

Resultados:

Model	Validation (%)					Test (%)				
	AUC	Acc	Sens	Spec	F1	AUC	Acc	Sens	Spec	F1
ResNet50	93.72	88.07	88.00	88.10	81.99	88.84	80.93	73.03	85.12	72.63
DenseNet121	94.10	87.24	86.67	87.50	80.75	86.51	80.54	73.03	84.52	72.22
ViT-S	96.36	88.48	96.00	85.12	83.72	87.47	80.93	77.53	82.74	73.80
Swin-T	95.86	90.95	86.67	92.86	85.53	86.96	84.44	67.42	93.45	75.00
MaxViT-T	92.75	87.65	82.67	89.88	80.52	86.89	82.49	69.66	89.29	73.37

Fonte: Artigo completo apresentado no 39º IEEE INTERNATIONAL SYMPOSIUM ON COMPUTER-BASED MEDICAL SYSTEMS (CBMS), 2026. Atualmente em processo de publicação. Favoreto, G. S.; Aguiar, E. J.; Campos, L. O.; Cazzolato, M. T.; Santos, M. K.; Traina, A. J. M.. Knowledge Distillation with Hybrid Soft-Label Losses for Imbalanced Lung Nodule Classification. 2026, Limassol, Cyprus.

Produção Científica

Knowledge Distillation with Hybrid Soft-Label Losses for Imbalanced Lung Nodule Classification

Resultados:

Teacher	Student	$\mathcal{L}_{KL}$	τ_{KL}^*	Best Hybrid	Best Loss	τ_{hyb}^*	Δ
ResNet-50	EfficientNet-B0	85.6	30	87.6	$\mathcal{L}_{KL+MSE+Foc}$	10	+2.0
	MobileNetV2	84.6	4	88.6	$\mathcal{L}_{KL+MSE}$	10	+4.0
DenseNet-121	EfficientNet-B0	85.0	30	87.0	$\mathcal{L}_{KL+MSE}$	4	+0.7
	MobileNetV2	84.9	4	88.9	$\mathcal{L}_{KL+MSE}$	10	+2.3
ViT-Small	EfficientNet-B0	85.0	30	87.0	$\mathcal{L}_{KL+MSE+Foc}$	30	+0.1
	MobileNetV2	84.1	4	88.1	$\mathcal{L}_{KL+MSE}$	4	+2.7
Swin-T	EfficientNet-B0	85.1	4	86.4	$\mathcal{L}_{KL+MSE}$	10	+1.3
	MobileNetV2	82.2	30	84.2	$\mathcal{L}_{KL+MSE}$	4	+2.0
MaxViT-T	EfficientNet-B0	86.9	4	88.1	$\mathcal{L}_{KL+MSE}$	30	+1.2
	MobileNetV2	85.1	10	87.0	$\mathcal{L}_{KL+MSE}$	30	+1.9
Average		84.7	–	86.5	–	–	+1.8

KL + MSE obteve o melhor desempenho

Losses híbridas superaram KL

Fonte: Artigo completo apresentado no 39º IEEE INTERNATIONAL SYMPOSIUM ON COMPUTER-BASED MEDICAL SYSTEMS (CBMS), 2026. Atualmente em processo de publicação. Favoreto, G. S.; Aguiar, E. J.; Campos, L. O.; Cazzolato, M. T.; Santos, M. K.; Traina, A. J. M.. Knowledge Distillation with Hybrid Soft-Label Losses for Imbalanced Lung Nodule Classification. 2026, Limassol, Cyprus.

Produção Científica

Knowledge Distillation with Hybrid Soft-Label Losses for Imbalanced Lung Nodule Classification

Resultados:

Role	Model	Params (M)	Size (MB)
Teacher	ResNet-50	23.5	89.7
	DenseNet-121	6.96	26.5
	ViT-Small	21.7	82.7
	Swin-Transformer	86.7	330.9
	MaxViT-Tiny	30.4	116.0
Student	EfficientNet-B0	4.01	15.3
	MobileNetV2	2.23	8.5


Maior redução de 97%

Fonte: Artigo completo apresentado no 39º IEEE INTERNATIONAL SYMPOSIUM ON COMPUTER-BASED MEDICAL SYSTEMS (CBMS), 2026. Atualmente em processo de publicação. Favoreto, G. S.; Aguiar, E. J.; Campos, L. O.; Cazzolato, M. T.; Santos, M. K.; Traina, A. J. M.. Knowledge Distillation with Hybrid Soft-Label Losses for Imbalanced Lung Nodule Classification. 2026, Limassol, Cyprus.

Produção Científica

Knowledge Distillation with Hybrid Soft-Label Losses for Imbalanced Lung Nodule Classification

Resultados:




Fonte: Artigo completo apresentado no 39º IEEE INTERNATIONAL SYMPOSIUM ON COMPUTER-BASED MEDICAL SYSTEMS (CBMS), 2026. Atualmente em processo de publicação. Favoreto, G. S.; Aguiar, E. J.; Campos, L. O.; Cazzolato, M. T.; Santos, M. K.; Traina, A. J. M.. Knowledge Distillation with Hybrid Soft-Label Losses for Imbalanced Lung Nodule Classification. 2026, Limassol, Cyprus.

Produção Científica

Knowledge Distillation with Hybrid Soft-Label Losses for Imbalanced Lung Nodule Classification

Resultados:



Fonte: Artigo completo apresentado no 39º IEEE INTERNATIONAL SYMPOSIUM ON COMPUTER-BASED MEDICAL SYSTEMS (CBMS), 2026. Atualmente em processo de publicação. Favoreto, G. S.; Aguiar, E. J.; Campos, L. O.; Cazzolato, M. T.; Santos, M. K.; Traina, A. J. M.. Knowledge Distillation with Hybrid Soft-Label Losses for Imbalanced Lung Nodule Classification. 2026, Limassol, Cyprus.



02

Produção Científica


CoSegXAI: A Pipeline for Context vs. Segmented ROI Images in
Lung Disease Classification through Saliency Map Insights

Produção Científica

CoSegXAI: A Pipeline for Context vs. Segmented ROI Images in Lung Disease Classification through Saliency Map Insights



Avaliar a segmentação como técnica de pré-processamento




Analisar mapas de saliência gerados por Grad-CAM

Fonte: dos Santos Favoreto, G., Suzuki Uchida, M. A., Luiz, P. A., Julio de Aguiar, E., Koenigkam Santos, M., Machado Traina, A. J. (2026). CoSegXAI: A Pipeline for Context vs. Segmented ROI Images in Lung Disease Classification through Saliency Map Insights. Revista De Informática Teórica E Aplicada, 33(2), 73–80. <https://doi.org/10.22456/2175-2745.150955>

Produção Científica

CoSegXAI: A Pipeline for Context vs. Segmented ROI Images in Lung Disease Classification through Saliency Map Insights

Metodologia:




Fonte: dos Santos Favoreto, G., Suzuki Uchida, M. A., Luiz, P. A., Julio de Aguiar, E., Koenigkam Santos, M., Machado Traina, A. J. (2026). CoSegXAI: A Pipeline for Context vs. Segmented ROI Images in Lung Disease Classification through Saliency Map Insights. Revista De Informática Teórica E Aplicada, 33(2), 73–80. <https://doi.org/10.22456/2175-2745.150955>

Produção Científica

CoSegXAI: A Pipeline for Context vs. Segmented ROI Images in Lung Disease Classification through Saliency Map Insights

Metodologia:




Fonte: dos Santos Favoreto, G., Suzuki Uchida, M. A., Luiz, P. A., Julio de Aguiar, E., Koenigkam Santos, M., Machado Traina, A. J. (2026). CoSegXAI: A Pipeline for Context vs. Segmented ROI Images in Lung Disease Classification through Saliency Map Insights. Revista De Informática Teórica E Aplicada, 33(2), 73–80. <https://doi.org/10.22456/2175-2745.150955>

Produção Científica

CoSegXAI: A Pipeline for Context vs. Segmented ROI Images in Lung Disease Classification through Saliency Map Insights

Metodologia:




Fonte: dos Santos Favoreto, G., Suzuki Uchida, M. A., Luiz, P. A., Julio de Aguiar, E., Koenigkam Santos, M., Machado Traina, A. J. (2026). CoSegXAI: A Pipeline for Context vs. Segmented ROI Images in Lung Disease Classification through Saliency Map Insights. Revista De Informática Teórica E Aplicada, 33(2), 73–80. <https://doi.org/10.22456/2175-2745.150955>

Produção Científica

CoSegXAI: A Pipeline for Context vs. Segmented ROI Images in Lung Disease Classification through Saliency Map Insights

Metodologia:




Fonte: dos Santos Favoreto, G., Suzuki Uchida, M. A., Luiz, P. A., Julio de Aguiar, E., Koenigkam Santos, M., Machado Traina, A. J. (2026). CoSegXAI: A Pipeline for Context vs. Segmented ROI Images in Lung Disease Classification through Saliency Map Insights. Revista De Informática Teórica E Aplicada, 33(2), 73–80. <https://doi.org/10.22456/2175-2745.150955>

Produção Científica

CoSegXAI: A Pipeline for Context vs. Segmented ROI Images in Lung Disease Classification through Saliency Map Insights

Metodologia:



Fonte: dos Santos Favoreto, G., Suzuki Uchida, M. A., Luiz, P. A., Julio de Aguiar, E., Koenigkam Santos, M., Machado Traina, A. J. (2026). CoSegXAI: A Pipeline for Context vs. Segmented ROI Images in Lung Disease Classification through Saliency Map Insights. Revista De Informática Teórica E Aplicada, 33(2), 73–80. <https://doi.org/10.22456/2175-2745.150955>

Produção Científica

CoSegXAI: A Pipeline for Context vs. Segmented ROI Images in Lung Disease Classification through Saliency Map Insights


Model	ACC↑	Pr↑	Rc↑	F1↑	AUC↑	MCC↑
<i>Contextual</i>						
ResNet50	90.81	91.45	90.81	90.71	98.30	0.860
DenseNet201	92.80	93.23	92.80	92.73	98.62	0.891
VGG19	88.17	89.44	88.17	87.92	98.12	0.821
<i>ROI-based</i>						
ResNet50	85.75	87.31	85.75	85.25	97.17	0.783
DenseNet201	88.08	88.96	88.08	87.79	97.90	0.818
VGG19	82.70	85.15	82.70	81.90	96.90	0.737

Note: Bold indicates the best value. All metrics (except MCC) are expressed in (%). An upward arrow (↑) indicates that higher values represent better performance. **ACC**: Accuracy, **Pr**: Precision, **Rc**: Recall, **F1**: F1-score, **AUC**: Area Under Curve, **MCC**: Matthew's Correlation Coefficient.

Fonte: dos Santos Favoreto, G., Suzuki Uchida, M. A., Luiz, P. A., Julio de Aguiar, E., Koenigkam Santos, M., Machado Traina, A. J. (2026). CoSegXAI: A Pipeline for Context vs. Segmented ROI Images in Lung Disease Classification through Saliency Map Insights. Revista De Informática Teórica E Aplicada, 33(2), 73–80. <https://doi.org/10.22456/2175-2745.150955>

Produção Científica


CoSegXAI: A Pipeline for Context vs. Segmented ROI Images in Lung Disease Classification through Saliency Map Insights



Fonte: dos Santos Favoreto, G., Suzuki Uchida, M. A., Luiz, P. A., Julio de Aguiar, E., Koenigkam Santos, M., Machado Traina, A. J. (2026). CoSegXAI: A Pipeline for Context vs. Segmented ROI Images in Lung Disease Classification through Saliency Map Insights. Revista De Informática Teórica E Aplicada, 33(2), 73–80. <https://doi.org/10.22456/2175-2745.150955>

Links úteis

CNN Explainer




Links úteis

MedMNIST

Data [[Zenodo](#)] Code [[GitHub](#)] Preprint [[arXiv](#)]
Publication [[Nature Scientific Data'23](#) / [ISBI'21](#)]

Disclaimer: The only official distribution link for the MedMNIST dataset is [Zenodo](#).
We kindly request users to refer to this original dataset link for accurate and up-to-date data.



Links úteis

Knowledge Distillation Tutorial — PyTorch Tutorials 2.14.0+cu130 documentation

The screenshot shows the PyTorch documentation page for the Knowledge Distillation Tutorial. The page has a dark theme. At the top, there's a navigation bar with 'PyTorch v2.14.0+cu130' and various dropdown menus like 'Intro', 'Compilers', 'Domains', 'Distributed', 'Deep Dive', 'Extension', 'Ecosystem', and 'More'. A search bar is on the right. The left sidebar contains a list of topics, with 'Knowledge Distillation Tutorial' highlighted. The main content area has a breadcrumb 'Deep Dive > Knowledge...', a 'Run in Google Colab' button, a 'Download Notebook' button, and a 'View on GitHub' button. The title 'Knowledge Distillation Tutorial' is prominently displayed. Below it, the creation and update dates are listed. The author is 'Alexandros Chariton'. The text explains that knowledge distillation is a technique for transferring knowledge from large, expensive models to smaller ones. It mentions that the tutorial will focus on improving the accuracy of a lightweight neural network using a more powerful one as a teacher. The tutorial uses 'torch' and 'torchvision' libraries. A list of topics to be learned is provided at the bottom. The right sidebar shows 'On this page' with 'Prerequisites' and a list of 'PyTorch Libraries' including ExecuTorch, Helion, torchao, kineto, torchtitan, TorchRL, torchvision, torchaudio, tensordict, and PyTorch on XLA Devices.

PyTorch v2.14.0+cu130

Intro ▾ Compilers ▾ Domains ▾ Distributed ▾ Deep Dive ▾ Extension ▾ Ecosystem ▾ More ▾

Go to [pytorch.org](#)

Search the docs ...

and profiling
(Beta) Implementing High-Performance Transformers with Scaled Dot Product Attention (SDPA)
Knowledge Distillation Tutorial
Frontend APIs
Channels Last
Memory Format in PyTorch
Forward-mode Automatic Differentiation (Beta)
Jacobians, Hessians, hvp, vhp, and more: composing function transforms
Model ensembling

🏠 > Deep Dive > Knowledge...

Rate this Page ★★★★★

[Run in Google Colab](#) [Download Notebook](#) [View on GitHub](#)

Knowledge Distillation Tutorial

Created On: Aug 22, 2023 | Last Updated: Jan 24, 2025 | Last Verified: Nov 05, 2024

Author: [Alexandros Chariton](#)

Knowledge distillation is a technique that enables knowledge transfer from large, computationally expensive models to smaller ones without losing validity. This allows for deployment on less powerful hardware, making evaluation faster and more efficient.

In this tutorial, we will run a number of experiments focused at improving the accuracy of a lightweight neural network, using a more powerful network as a teacher. The computational cost and the speed of the lightweight network will remain unaffected, our intervention only focuses on its weights, not on its forward pass. Applications of this technology can be found in devices such as drones or mobile phones. In this tutorial, we do not use any external packages as everything we need is available in `torch` and `torchvision`.

In this tutorial, you will learn:

- How to modify model classes to extract hidden representations and use them for further calculations
- How to modify regular train loops in PyTorch to include additional losses on top of, for example, cross-entropy for classification

On this page
Prerequisites

PyTorch Libraries

- [ExecuTorch](#)
- [Helion](#)
- [torchao](#)
- [kineto](#)
- [torchtitan](#)
- [TorchRL](#)
- [torchvision](#)
- [torchaudio](#)
- [tensordict](#)
- [PyTorch on XLA Devices](#)

Links úteis

X EABDA - ICMC-USP

Escola Avançada 
Big Data Analysis



Escola Avançada de Big Data Analysis Cursos Online e Gratuitos com Certificados USP

A X Escola Avançada de Big Data Analysis conta com cursos gratuitos que visam apresentar as principais técnicas usadas para a análise inteligente de grandes volumes de dados, com teoria e prática. Os cursos serão ministrados online e de forma síncrona (ou seja, transmissões ao vivo), com emissão de certificados reconhecidos pela USP.

Para obter o certificado, é exigida uma **frequência mínima de 75%** na carga horária total da Escola. Portanto, é necessário cumprir 100% de presença em **pelo menos 4 dos 5 cursos** do evento. O registro de frequência será realizado de forma contínua ao longo de cada aula.

Saiba mais detalhes [clcando aqui](#).

CONHEÇA OS CURSOS

INSCREVA-SE

Links úteis

GBDI - Database and Image Group

